

**Prof. MSc. Marcos Alexandruk**

**E-mail: [alexandruk@uni9.pro.br](mailto:alexandruk@uni9.pro.br)**

**<https://github.com/alexandruk/analisededados>**

# **Estatística**

## Estatística

A palavra estatística tem origem no latim "**status**" e relaciona-se com "**estado**".

No início, a palavra era usada para se referir ao "**cidadão político**".

Posteriormente, passou a ser utilizada em alemão com o sentido de "**conjunto de dados do Estado**", de onde decorre o seu significado desde o século XIX.

BATISTA, Carolina. Estatística. Toda Matéria, 2021. Disponível em: <https://www.todamateria.com.br/estatistica-conceito-fases-metodo/>. Acesso em: 23/02/2021.

## Estatística

“Estatística é uma ciência exata que estuda a coleta, a organização, a análise e registro de dados por amostras.

Utilizada desde a Antiguidade, quando se registravam os nascimentos e as mortes das pessoas, é um método de pesquisa fundamental para tomar decisões. Isso porque fundamenta suas conclusões nos estudos realizados.”

BATISTA, Carolina. Estatística. Toda Matéria, 2021. Disponível em: <https://www.todamateria.com.br/estatistica-conceito-fases-metodo/>. Acesso em: 23/02/2021.

## Estatística

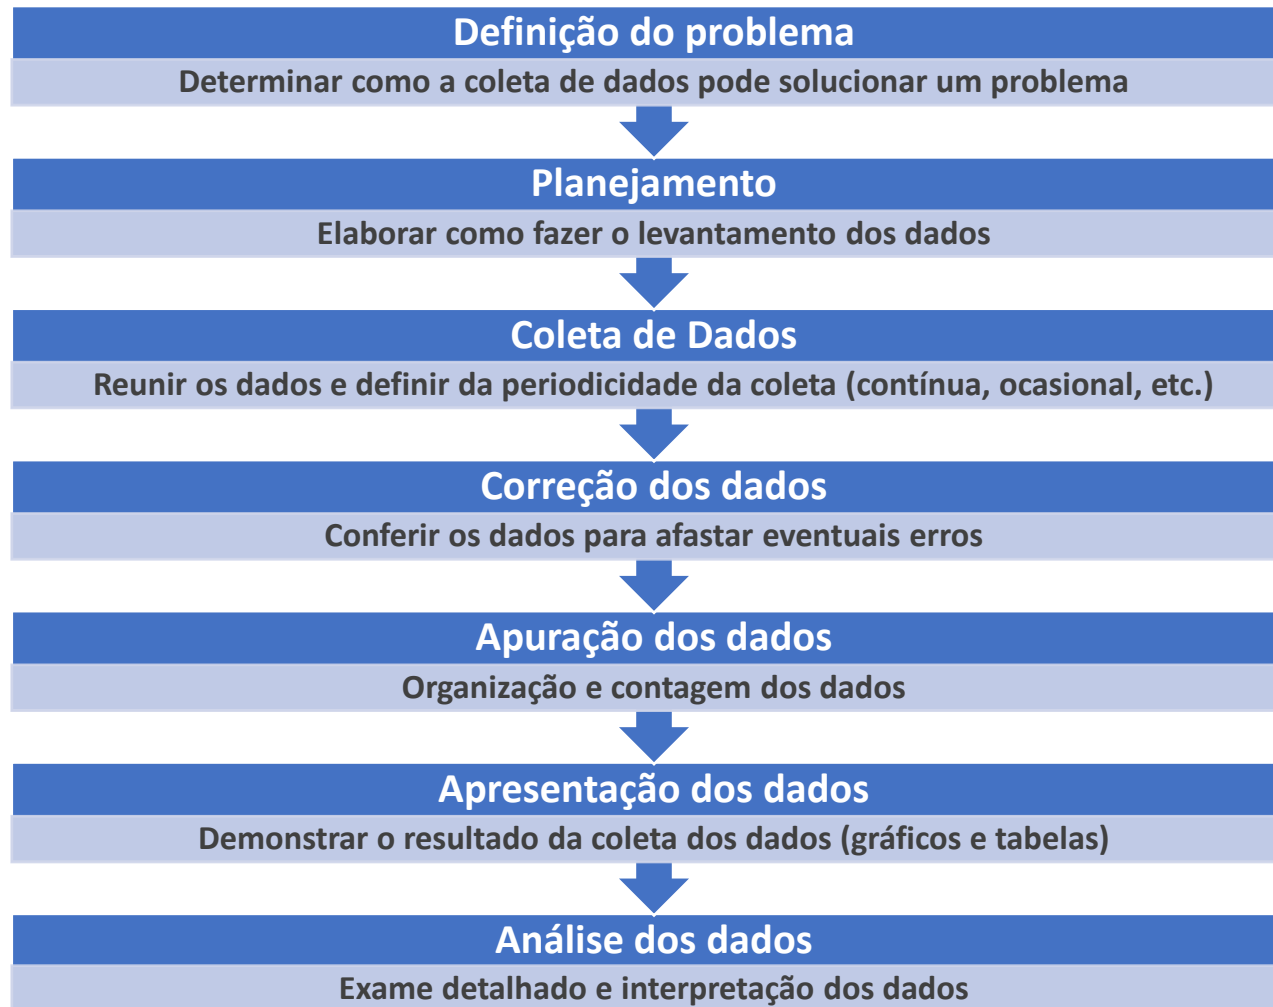
Estatística é ciência que tem por fim a **pesquisa e a comparação dos fatos gerais e particulares** verificados no movimento das sociedades.

## Objetivo geral da estatística

O objetivo da estatística é a análise e interpretação dos fenômenos sociais de qualquer natureza, para planejamento de ações.

# Análise de Dados

## Fases do Método Estatístico



BATISTA, Carolina. Estatística. Toda Matéria, 2021. Disponível em: <https://www.todamateria.com.br/estatistica-conceito-fases-metodo/>. Acesso em: 23/02/2021. (adaptado)

## Importância da Estatística na Engenharia

A probabilidade e estatística pode contribuir para mitigação dos erros e favorecer a análise de um projeto em construção, considerando as mais diversas situações, de forma que dados estatísticos podem auxiliar os testes de desempenho e o controle de qualidade.



## Análise Descritiva

A análise descritiva dos dados se limita a calcular algumas medidas de posição e variabilidade, como a média e variância, por exemplo.

## Inferência

Inferência estatística é um ramo da Estatística cujo objetivo é fazer afirmações a partir de um conjunto de valores representativo (amostra) sobre um universo.

Em geral, a inferência estatística está associada à coleta, à redução, à análise e à modelagem dos dados.

## Tipos de Variáveis

**Variáveis qualitativas:** apresentam algum tipo de atributo do elemento pesquisado. (educação, estado civil, sexo, etc.)

**Variáveis quantitativas:** apontam para um impacto no elemento pesquisado e contribuem na análise.

**Variáveis quantitativas discretas:** Quando podemos expressar as variáveis por um número inteiro em certa contagem, chamamos de variável quantitativa discreta. (número de filhos, quantidade de veículos, etc.)

**Variáveis quantitativas contínuas:** Quando destacamos uma variável por intermédio de uma medida, chamamos de variável quantitativa contínua. (tempo, temperatura, pressão, etc.)

## Distribuições de frequências

No estudo de uma variável, devemos dispor um maior interesse em conhecer a distribuição dessa variável por meio das possíveis realizações dela e dispor seus valores, de modo que se tenha uma boa ideia global dessa distribuição.

## Distribuições de frequências

Frequência de porcentagens de 20 empregados segundo o grau de instrução:

| Grau de instrução | Contagem  | Frequência | Proporção   | Porcentagem |
|-------------------|-----------|------------|-------------|-------------|
| 1º grau           | 8         | 8          | 0,4         | 40%         |
| 2º grau           | 7         | 7          | 0,35        | 35%         |
| Superior          | 5         | 5          | 0,25        | 25%         |
| <b>Total</b>      | <b>20</b> | <b>20</b>  | <b>1,00</b> | <b>100%</b> |

## Distribuições de frequências

Frequência absoluta acumulada e frequência relativa acumulada:

| Grau de instrução | Frequência Absoluta | Frequência Relativa | Frequência Absoluta Acumulada | Frequência Relativa Acumulada |
|-------------------|---------------------|---------------------|-------------------------------|-------------------------------|
| 1º grau           | 8                   | 40%                 | 8                             | 40%                           |
| 2º grau           | 7                   | 35%                 | $8 + 7 = 15$                  | $40\% + 35\% = 75\%$          |
| Superior          | 5                   | 25%                 | $15 + 5 = 20$                 | $75\% + 25\% = 100\%$         |
| <b>Total</b>      | <b>20</b>           | <b>100%</b>         | <b>20</b>                     | <b>100%</b>                   |

As frequências acumuladas são extremamente úteis quando o objetivo é saber a quantidade ou a porcentagem até determinada característica.

## Amplitude total

Alturas de 32 crianças de 1 a 4 anos:

|              |       |       |       |       |       |       |              |
|--------------|-------|-------|-------|-------|-------|-------|--------------|
| <b>73,93</b> | 71,51 | 66,83 | 64,17 | 66,16 | 65,7  | 64,78 | 65,81        |
| 63,15        | 62,56 | 61,88 | 60,94 | 60,3  | 60,15 | 56,57 | 55,86        |
| 71,47        | 70,09 | 64,44 | 63,27 | 66,06 | 65,09 | 64,73 | 64,16        |
| 62,69        | 61,91 | 61,49 | 60,73 | 60,24 | 59,37 | 56,03 | <b>55,77</b> |

Amplitude total = Valor Máximo – Valor Mínimo

Amplitude total = 73,93 – 55,77

Amplitude total = 18,16

## Números de classes

Alturas de 32 crianças de 1 a 4 anos:

|              |       |       |       |       |       |       |              |
|--------------|-------|-------|-------|-------|-------|-------|--------------|
| <b>73,93</b> | 71,51 | 66,83 | 64,17 | 66,16 | 65,7  | 64,78 | 65,81        |
| 63,15        | 62,56 | 61,88 | 60,94 | 60,3  | 60,15 | 56,57 | 55,86        |
| 71,47        | 70,09 | 64,44 | 63,27 | 66,06 | 65,09 | 64,73 | 64,16        |
| 62,69        | 61,91 | 61,49 | 60,73 | 60,24 | 59,37 | 56,03 | <b>55,77</b> |

Número de classes = SQRT (n)

Número de classes = SQRT (32)

Número de classes = 5,65 (aproximado para 6)

SQRT => Raiz Quadrada



## Amplitude do intervalo

Amplitude do intervalo = Amplitude total / número de classes

Amplitude do intervalo = 18,16 / 6

Amplitude do intervalo = 3,02

| Classes            | fi        | Fi | fr          | Fr     |
|--------------------|-----------|----|-------------|--------|
| 55 ┤               | 4         | 4  | 12,50%      | 12,50% |
| 58 ┤               | 6         | 10 | 18,75%      | 31,25% |
| 61 ┤               | 7         | 17 | 21,88%      | 53,13% |
| 64 ┤               | 11        | 28 | 34,38%      | 87,50% |
| 67 ┤               | 1         | 29 | 3,13%       | 90,63% |
| 70 ┤ <b>[ERRO]</b> | 3         | 32 | 9,38%       | 100%   |
| <b>Total</b>       | <b>32</b> |    | <b>100%</b> |        |

## Amplitude do intervalo

Amplitude do intervalo = Amplitude total / número de classes

Amplitude do intervalo = 18,16 / 6

Amplitude do intervalo = 3,02

| Classes               | fi        | Fi | fr          | Fr     |
|-----------------------|-----------|----|-------------|--------|
| 55 ┆ 58               | 4         | 4  | 12,50%      | 12,50% |
| 58 ┆ 61               | 6         | 10 | 18,75%      | 31,25% |
| 61 ┆ 64               | 7         | 17 | 21,88%      | 53,13% |
| 64 ┆ 67               | 11        | 28 | 34,38%      | 87,50% |
| 67 ┆ 70               | 1         | 29 | 3,13%       | 90,63% |
| 70 ┆ 73 <b>[ERRO]</b> | 3         | 32 | 9,38%       | 100%   |
| <b>Total</b>          | <b>32</b> |    | <b>100%</b> |        |

**[ERRO]** O maior valor é 73,93 (está acima de 73)

## Amplitude do intervalo

Amplitude do intervalo = Amplitude total / número de classes

Amplitude do intervalo =  $18,16 / 6$

Amplitude do intervalo = 3,02 (arredondar para 4)

| Classes      | fi        | Fi | fr          | Fr |
|--------------|-----------|----|-------------|----|
| 55 † 59      |           |    |             |    |
| 59 † 63      |           |    |             |    |
| 63 † 67      |           |    |             |    |
| 67 † 71      |           |    |             |    |
| 71 † 75      |           |    |             |    |
| 75 † 79      |           |    |             |    |
| <b>Total</b> | <b>32</b> |    | <b>100%</b> |    |

## Regra de Sturges

$$k = 1 + 3,3 * \text{LOG}(n)$$

k = Número de classes

n = Total de dados

$$A_{\text{Total}} = \text{Valor}_{\text{Max}} - \text{Valor}_{\text{Min}}$$

$$h = A_{\text{Total}}/k$$

h = Amplitude do Intervalo

$$k = 1 + 3,3 * \text{LOG}(20)$$

$$k = 5,293399$$

$$k \approx 5$$

$$A_{\text{Total}} = 42 - 15$$

$$A_T = 27$$

$$h = 27/5$$

$$h = 5,4$$

$$h \approx 6$$

(Arredondar para cima)

| Pesquisa: Idade |    |    |    |    |
|-----------------|----|----|----|----|
| 17              | 18 | 16 | 24 | 23 |
| 42              | 40 | 36 | 15 | 18 |
| 26              | 23 | 23 | 24 | 28 |
| 41              | 16 | 18 | 20 | 27 |

| IDADE   | fi |
|---------|----|
| 15 - 21 | 8  |
| 15 - 27 | 6  |
| 27 - 33 | 2  |
| 33 - 39 | 1  |
| 39 - 45 | 3  |

## Exercício

| SALÁRIOS |       |       |       |       |       |
|----------|-------|-------|-------|-------|-------|
| 20,50    | 9,50  | 15,30 | 17,20 | 24,10 | 19,90 |
| 15,40    | 12,70 | 7,40  | 16,50 | 15,30 | 26,20 |
| 14,90    | 7,80  | 23,30 | 15,90 | 11,80 | 18,40 |
| 13,40    | 14,30 | 16,20 | 16,70 | 9,20  | 16,80 |
| 9,80     | 20,10 | 17,80 | 17,10 | 12,60 | 15,90 |

| Classes       | fi |
|---------------|----|
| 7,40 ┤ 10,40  |    |
| 10,40 ┤ 13,60 |    |
| 13,60 ┤ 16,80 |    |
| 16,80 ┤ 20,00 |    |
| 20,00 ┤ 23,20 |    |
| 23,20 ┤ 26,40 |    |

|                                   |  |
|-----------------------------------|--|
| Amplitude Total ( $A_{Total}$ ) = |  |
|-----------------------------------|--|

|                      |  |
|----------------------|--|
| Total de dados (n) = |  |
|----------------------|--|

|                         |  |
|-------------------------|--|
| Número de classes (k) = |  |
|-------------------------|--|

|                              |  |
|------------------------------|--|
| Amplitude do intervalo (h) = |  |
|------------------------------|--|

## Exercício

| SALÁRIOS |       |       |       |       |       |
|----------|-------|-------|-------|-------|-------|
| 20,50    | 9,50  | 15,30 | 17,20 | 24,10 | 19,90 |
| 15,40    | 12,70 | 7,40  | 16,50 | 15,30 | 26,20 |
| 14,90    | 7,80  | 23,30 | 15,90 | 11,80 | 18,40 |
| 13,40    | 14,30 | 16,20 | 16,70 | 9,20  | 16,80 |
| 9,80     | 20,10 | 17,80 | 17,10 | 12,60 | 15,90 |

| Classes       | fi |
|---------------|----|
| 7,40 † 10,60  |    |
| 10,60 † 13,80 |    |
| 13,80 † 17,00 |    |
| 17,00 † 20,20 |    |
| 20,20 † 23,40 |    |
| 23,40 † 26,60 |    |

$$k = 1 + 3,3 * \text{LOG}(n)$$

k = Número de classes

n = Total de dados

$$A_{\text{Total}} = \text{Valor}_{\text{Max}} - \text{Valor}_{\text{Min}}$$

$$h = A_{\text{Total}}/k$$

h = Amplitude do Intervalo

$$k = 1 + 3,3 * \text{LOG}(30)$$

$$k = 6$$

$$A_{\text{Total}} = 26,20 - 7,40$$

$$h = 18,80/6$$

$$k \approx 6$$

$$A_T = 18,80$$

$$h = 3,13$$

$$h \approx 3,20$$

(Arredondar para cima)

## Exercício

| SALÁRIOS |       |       |       |       |       |
|----------|-------|-------|-------|-------|-------|
| 20,50    | 9,50  | 15,30 | 17,20 | 24,10 | 19,90 |
| 15,40    | 12,70 | 7,40  | 16,50 | 15,30 | 26,20 |
| 14,90    | 7,80  | 23,30 | 15,90 | 11,80 | 18,40 |
| 13,40    | 14,30 | 16,20 | 16,70 | 9,20  | 16,80 |
| 9,80     | 20,10 | 17,80 | 17,10 | 12,60 | 15,90 |

| Classes       | fi |
|---------------|----|
| 7,40 ┆ 10,60  | 5  |
| 10,60 ┆ 13,80 | 4  |
| 13,80 ┆ 17,00 | 11 |
| 17,00 ┆ 20,20 | 6  |
| 20,20 ┆ 23,40 | 2  |
| 23,40 ┆ 26,60 | 2  |
| TOTAL VALORES | 30 |

|                                   |       |
|-----------------------------------|-------|
| Amplitude Total ( $A_{Total}$ ) = | 18,80 |
|-----------------------------------|-------|

|                      |    |
|----------------------|----|
| Total de dados (n) = | 30 |
|----------------------|----|

|                         |   |
|-------------------------|---|
| Número de classes (k) = | 6 |
|-------------------------|---|

|                              |      |
|------------------------------|------|
| Amplitude do intervalo (h) = | 3,20 |
|------------------------------|------|

## Exercício

| Classes       | fi | Fi | fr     | Fr      |
|---------------|----|----|--------|---------|
| 7,40 ┆ 10,60  | 5  | 5  | 16,66% | 16,66%  |
| 10,60 ┆ 13,80 | 4  | 9  | 13,33% | 30,00%  |
| 13,80 ┆ 17,00 | 11 | 20 | 36,66% | 66,66%  |
| 17,00 ┆ 20,20 | 6  | 26 | 20,00% | 86,66%  |
| 20,20 ┆ 23,40 | 2  | 28 | 6,66%  | 93,33%  |
| 23,40 ┆ 26,60 | 2  | 30 | 6,66%  | 100,00% |
| Total         | 30 |    | 100%%  |         |

fi = frequência absoluta

Fi = frequência absoluta acumulada

fr = frequência relativa

Fr = frequência relativa acumulada




## Referências

DACHS J. N. W. Análise de dados e regressão. São Paulo: IME USP, 1978.

LEVIN J. Estatística aplicada a Ciências Humanas. São Paulo: Harper e Row do Brasil, 1978.

MORETTIN P. A. Introdução a estatística para ciências exatas. São Paulo: Atual Editora, 1981.



**Prof. MSc. Marcos Alexandruk**


**E-mail: [alexandruk@uni9.pro.br](mailto:alexandruk@uni9.pro.br)**

**<https://github.com/alexandruk/analisededados>**

# Representações gráficas


# Análise de Dados

| Produtos | Quantidade |
|----------|------------|
| A        | 35         |
| B        | 25         |
| C        | 45         |
| D        | 10         |



# Análise de Dados

| Classes | Frequências |
|---------|-------------|
| 0-2     | 3           |
| 2-4     | 6           |
| 4-6     | 8           |
| 6-8     | 5           |
| 8-10    | 2           |




# Análise de Dados

| Medição | Temperatura |
|---------|-------------|
| 1       | 38,4        |
| 2       | 37,0        |
| 3       | 38,7        |
| 4       | 38,5        |
| 5       | 38,0        |
| 6       | 37,3        |
| 7       | 36,5        |
| 8       | 36,0        |
| 9       | 37,0        |
| 10      | 37,9        |
| 11      | 37,6        |
| 12      | 36,8        |



# Análise de Dados


| Medição | Temperatura |
|---------|-------------|
| 1       | 38,4        |
| 2       | 37,0        |
| 3       | 38,7        |
| 4       | 38,5        |
| 5       | 38,0        |
| 6       | 37,3        |
| 7       | 36,5        |
| 8       | 36,0        |
| 9       | 37,0        |
| 10      | 37,9        |
| 11      | 37,6        |
| 12      | 36,8        |



# Análise de Dados

| Produtos | Quantidade (%) |
|----------|----------------|
| A        | 32,4           |
| B        | 13,6           |
| C        | 43,2           |
| D        | 10,8           |


Gráfico de Setores (Pizza)






# Análise de Dados

|    |    |
|----|----|
| SP | 10 |
| SP | 5  |
| SP | 30 |
| SP | 12 |
| SP | 10 |
| SP | 20 |
| SP | 14 |
| SP | 10 |
| RJ | 12 |
| RJ | 60 |
| RJ | 5  |
| RJ | 15 |
| RJ | 18 |
| RJ | 12 |
| RJ | 14 |
| MG | 10 |
| MG | 10 |
| MG | 12 |
| MG | 5  |
| MG | 14 |
| MG | 25 |
| MG | 12 |
| MG | 20 |
| MG | 15 |





**Prof. MSc. Marcos Alexandruk**

**E-mail: [alexandruk@uni9.pro.br](mailto:alexandruk@uni9.pro.br)**

**<https://github.com/alexandruk/analisededados>**

**Medidas de tendência central:  
média aritmética; média geométrica; média harmônica**

## Média aritmética

### 1º caso: dados não agrupados

A média aritmética dos valores  $x_1, x_2, x_3, \dots, x_n$  é o quociente entre a soma desses valores e o seu número total  $n$ .

$$\bar{x} = \frac{x_1 + x_2 + x_3 + \dots + x_n}{n} \text{ ou } \bar{x} = \frac{\sum x_i}{n}$$

Exemplo: Determinar a média aritmética dos valores: 3, 7, 8, 10 e 11.

$$\bar{x} = \frac{3+7+8+10+11}{5} = 7,8$$

## Média aritmética

### 2º caso: dados agrupados sem intervalos

Se os elementos  $x_1, x_2, x_3, \dots, x_n$  apresentam, respectivamente, frequências  $f_1, f_2, f_3, \dots, f_n$ , então:

$$\bar{x} = \frac{x_1 f_1 + x_2 f_2 + x_3 f_3 + \dots + x_n f_n}{n} \text{ ou } \bar{x} = \frac{\sum x_i f_i}{n}$$

Exemplo: dada a amostra: 2, 5, 5, 5, 5, 6, 6, 6, 8, 8, a média será:

$$\bar{x} = \frac{2 \cdot 1 + 5 \cdot 4 + 6 \cdot 3 + 8 \cdot 2}{10} = \frac{56}{10} = 5,6$$

| $x_i$ | $f_i$ | $x_i f_i$ |
|-------|-------|-----------|
| 2     | 1     | 2         |
| 5     | 4     | 20        |
| 6     | 3     | 18        |
| 8     | 2     | 16        |
| Total | 10    | 56        |

## Média aritmética

### 3º caso: dados agrupados com intervalos

Quando os dados estão agrupados, aceita-se, por convenção, que as frequências se distribuam uniformemente ao longo da classe e que, portanto, o seu ponto médio ( $x$ ) é o valor representativo do conjunto. Então:

$$\bar{x} = \frac{x_1f_1 + x_2f_2 + x_3f_3 + \dots + x_nf_n}{n} \text{ ou } \bar{x} = \frac{\sum x_i f_i}{n}$$

Exemplo: dada a amostra conforme a tabela, a média será:

$$\bar{x} = \frac{3,5 \cdot 1 + 6,5 \cdot 10 + 9,5 \cdot 8 + 12,5 \cdot 1}{20} = \frac{157}{20} = 7,85$$

| Classe  | $x_i$ | $f_i$ | $x_i f_i$ |
|---------|-------|-------|-----------|
| 2 † 5   | 3,5   | 1     | 3,5       |
| 5 † 8   | 6,5   | 10    | 65        |
| 8 † 11  | 9,5   | 8     | 76        |
| 11 † 14 | 12,5  | 1     | 12,5      |
| Total   |       | 20    | 157       |

## Média geométrica

A média geométrica de um conjunto de números positivos é definida como o **produto de todos os membros do conjunto elevado ao inverso do número de membros**. Indica a tendência central ou o valor típico de um conjunto de números usando o produto dos seus valores.

A média geométrica é frequentemente utilizada quando comparamos diferentes itens – encontrando uma única "figura representativa" para esses itens – quando cada um desses itens possuem múltiplas propriedades que possuem diferentes escalas numéricas. Por exemplo, a média geométrica pode nos dar uma "média" significativa para comparar duas companhias que estão sendo classificadas numa escala de 0 a 5 para suas sustentabilidades ambientais e sendo classificadas de 0 a 100 para suas viabilidades financeiras. Se a média aritmética fosse usada em vez da média geométrica, a viabilidade financeira pesaria mais pois seu alcance numérico é grande, logo uma pequena mudança percentual na classificação financeira (por exemplo: uma mudança de 80 para 90) faria uma grande diferença na média aritmética do que uma grande diferença percentual na classificação da sustentabilidade ambiental (por exemplo uma mudança de 2 para 5 na escala).

## Média geométrica

Sejam  $x_1, x_2, x_3, \dots, x_n$  valores da variável  $X$ , associadas, respectivamente, às frequências  $f_1, f_2, f_3, \dots, f_n$ . Então, a média geométrica de  $x$  é definida por:

$$M_g = \sqrt[n]{x_1^{f_1} \cdot x_2^{f_2} \cdot x_3^{f_3} \cdot \dots \cdot x_n^{f_n}}$$

Em particular, se  $f_1, f_2, f_3, \dots, f_n = 1$ . temos:

$$M_g = \sqrt[n]{x_1 \cdot x_2 \cdot x_3 \cdot \dots \cdot x_n}$$

Exemplo: Dada a tabela de distribuição de frequências, temos:

$$M_g = \sqrt[22]{1^8 \cdot 2^6 \cdot 3^5 \cdot 5^3} = \sqrt[22]{1944000} = 1,93$$

| $x_i$ | $f_i$ |
|-------|-------|
| 1     | 8     |
| 2     | 6     |
| 3     | 5     |
| 5     | 3     |
| Total | 22    |



## Média harmônica

A média harmônica é definida como a quantidade de elementos no conjunto, dividida pela soma do inverso dos elementos do conjunto.

A média aritmética é muitas vezes utilizada erroneamente em casos que exigem a média harmônica. Um exemplo é o cálculo da velocidade média em um percurso de ida e volta em uma mesma via, em que a ida é percorrida a 60 km/h e a volta a 40 km/h a média aritmética de 50 está incorreta. A velocidade média no percurso total é a média harmônica de 40 e 60, ou seja 48km/h.

Exemplo:

Distância de A a B = 120 Km | Velocidade média = 40 Km/h | Duração da viagem =  $120 / 40 = 3$  horas

Distância de B a A = 120 Km | Velocidade média = 60 Km/h | Duração da viagem =  $120 / 60 = 2$  horas

Distância total de A a B + de B a A = 120 Km + 120 Km = 240 Km

Duração total da viagem = 3 horas + 2 horas = 5 horas

Velocidade média da viagem (de A a B + de B a A) =  $240 / 5 = 48$  Km/h

## Média harmônica

Se os elementos  $x_1, x_2, x_3, \dots, x_n$  apresentam, respectivamente, frequências  $f_1, f_2, f_3, \dots, f_n$ , então, a média harmônica é definida como o inverso da média aritmética do inverso dos valores:

$$M_h = \frac{n}{\frac{f_1}{x_1} + \frac{f_2}{x_2} + \frac{f_3}{x_3} + \dots + \frac{f_n}{x_n}} = \frac{n}{\sum \frac{f_i}{x_i}}$$

Em particular, se  $f_1, f_2, f_3, \dots, f_n = 1$ , temos:

$$M_h = \frac{n}{\frac{1}{x_1} + \frac{1}{x_2} + \frac{1}{x_3} + \dots + \frac{1}{x_n}} = \frac{n}{\sum \frac{1}{x_i}}$$

Exemplo: Dada a tabela de distribuição de frequências, temos:

$$M_h = \frac{22}{\frac{8}{1} + \frac{6}{2} + \frac{5}{3} + \frac{3}{5}} = \frac{22}{\frac{398}{30}} = 22 \cdot \frac{30}{398} = \frac{330}{199} = 1,66$$

| $x_i$ | $f_i$ |
|-------|-------|
| 1     | 8     |
| 2     | 6     |
| 3     | 5     |
| 5     | 3     |
| Total | 22    |



**Prof. MSc. Marcos Alexandruk**

**E-mail: [alexandruk@uni9.pro.br](mailto:alexandruk@uni9.pro.br)**

**<https://github.com/alexandruk/analisededados>**

## Medidas de tendência central: moda e mediana

## Objetivo

Calcular e interpretar as medidas de tendência central: a **moda** e a **mediana** de uma distribuição, destacando as suas diferenças e usos.

## Média, moda e mediana

Apesar de ser bastante utilizada a média aritmética, nem sempre é a medida mais adequada para se analisar um agrupamento de dados.

Veja o exemplo. Numa certa empresa com 200 empregados, os salários são os seguintes:

| Salários<br>(em salários mínimos) | Número de<br>empregados |
|-----------------------------------|-------------------------|
| 1                                 | 100                     |
| 2                                 | 30                      |
| 3                                 | 30                      |
| 4                                 | 5                       |
| 5                                 | 25                      |
| 10                                | 5                       |
| 25                                | 3                       |
| 40                                | 2                       |

Calculando o salário médio desses empregados, obtemos 3 salários mínimos.

Este número está correto do ponto de vista aritmético, mas não é representativo da condição salarial da maioria dos empregados. Afinal, 130 (65% do total) deles, ganham menos do que este valor. Por outro lado, de acordo com a tabela, 5 empregados (2,5%) ganham mais do que 20 salários mínimos, o que "puxa" a média para cima.

Neste caso, é mais conveniente usarmos outro tipo de medida como valor representativo do salário dos empregados, conforme veremos nesta aula.

## Moda

Dada uma coleção de números, a moda é o valor que ocorre com **maior frequência**.

Assim, no exemplo citado, o salário mais frequente é o salário mínimo, que é recebido por 100 empregados, isto é, 1 salário mínimo.

Observações:

- Existem casos em que a moda não existe — os valores não se repetem ou todos os valores têm a mesma frequência (distribuição amodal).
- Em alguns casos, pode haver mais de uma moda, ou seja, a distribuição dos valores pode ser bimodal, trimodal, etc.

## Moda ( $M_o$ )

### 1º Caso: dados não agrupados

É o valor de maior frequência ou que aparece mais vezes em um conjunto de dados.

Exemplo: **7, 8, 8, 9, 10, 10, 10, 12, 15**

O elemento de maior frequência é o 10, que aparece três vezes.

Portanto  $M_o = 10$  (distribuição unimodal).

Exemplo: **3, 5, 8, 10, 12 e 13**

Todos os elementos da série apresentam a mesma frequência, logo, a série é **amodal**.

Exemplo: **2, 2, 5, 5, 8, 9**

Os elementos 2 e 5 têm frequência 2. Logo, temos  $M_o = 2$  e  $M_o = 5$  (distribuição **bimodal**).



## Moda ( $M_o$ )

### 2º Caso: dados agrupados sem intervalos

Basta identificar o elemento de maior frequência.

| $x_i$    | $f_i$    |
|----------|----------|
| 0        | 2        |
| 2        | 4        |
| <b>3</b> | <b>5</b> |
| 4        | 3        |
| 6        | 1        |

Portanto,  $M_o = 3$

## Moda ( $M_o$ )

### 3º Caso: dados agrupados com intervalos

Neste caso, consideramos como moda o valor compreendido entre os limites da **classe modal**, ou seja, **aquela que apresenta a maior frequência**. Tal valor é dado por:

$$M_o = l_i + \frac{\Delta_1}{\Delta_1 + \Delta_2} \cdot h$$

Em que:

$l_i$  = limite inferior da classe modal

$\Delta_1$  = diferença entre a frequência ( $f_i$ ) da classe modal e a imediatamente anterior

$\Delta_2$  = diferença entre a frequência ( $f_i$ ) da classe modal e a imediatamente posterior

$h$  = amplitude da classe modal

## Moda ( $M_o$ )

### 3º Caso: dados agrupados com intervalos

Exemplo: Dada a tabela:

| classe  | $f_i$ |
|---------|-------|
| 0 - 10  | 1     |
| 10 - 20 | 3     |
| 20 - 30 | 6     |
| 30 - 40 | 2     |

**1º passo:** identifica-se a classe modal (aquela que apresenta maior frequência)  
No caso, trata-se da 3ª classe 20 - 30 ( $f_i=6$ )

**2º passo:** aplica-se a fórmula. No caso temos:

$$l_i = 20$$

$$\Delta_1 = 6 - 3 = 3$$

$$\Delta_2 = 6 - 2 = 4$$

$$h = 30 - 20 = 10$$

$$M_o = 20 + \frac{3}{3 + 4} \cdot 10$$

$$M_o = 20 + \frac{30}{7}$$


$$M_o = \frac{140 + 30}{7}$$

$$M_o = \frac{170}{7}$$

$$M_o = 24,29$$

## Mediana ( $\bar{x}$ )

Dada uma coleção de números colocados em ordem crescente, a mediana ( $\bar{x}$ ) é o valor que divide a amostra em duas partes iguais.



50% dos valores da série são valores menores ou iguais a  $\bar{x}$  e 50% dos valores da série são maiores ou iguais a  $\bar{x}$ .

## Mediana ( $\bar{x}$ )

### 1º Caso: dados não agrupados

Quando temos um número ímpar de elementos, dispostos em ordem crescente, a mediana é definida como sendo o elemento central, de ordem  $\frac{n+1}{2}$

Exemplo: 1, 2, 3, 4, 5

$$\bar{x} = 3$$

Se a coleção tiver um número par de elementos, também dispostos em ordem crescente, a mediana é definida como a média aritmética dos dois valores centrais, de ordem  $\frac{n}{2}$  e  $\frac{n}{2} + 1$

Exemplo: 2, 4, 6, 8, 10, 12

$$\bar{x} = \frac{6 + 8}{2} = \frac{14}{2} = 7$$

## Mediana ( $\bar{x}$ )

### 2º Caso: dados agrupados sem intervalos

Basta considerar a frequência acumulada e localizar a mediana, procedendo da mesma forma que no caso anterior.

Exemplo 1: Dada a distribuição:

| $x_i$     | $f_i$ |
|-----------|-------|
| 12        | 1     |
| 14        | 2     |
| 15        | 1     |
| <b>16</b> | 2     |
| 17        | 1     |
| 20        | 2     |
| Total     | 9     |

Como  $n = 9$  é ímpar, logo será o elemento de ordem  $\frac{n+1}{2}$  ou seja:

$$\bar{x} = \frac{n+1}{2} = \frac{9+1}{2} = \frac{10}{2} = 5 \text{ (5º elemento)}$$

## Mediana ( $\bar{x}$ )

### 2º Caso: dados agrupados sem intervalos

Exemplo 2: Dada a distribuição:

| $x_i$     | $f_i$ |
|-----------|-------|
| 12        | 2     |
| 14        | 2     |
| <b>15</b> | 2     |
| <b>16</b> | 2     |
| 17        | 2     |
| 20        | 2     |
| Total     | 12    |

Como  $n = 12$  é par, logo será o elemento de ordem  $\frac{n+1}{2}$  e  $\frac{n+1}{2} + 1$  ou seja:

$$\bar{x} = \frac{n}{2} e \frac{n}{2} + 1 = \frac{12}{2} e \frac{12}{2} + 1 = 6 \text{ e } 7 \text{ (6º e 7º elemento)}$$

## Mediana ( $\bar{x}$ )

### 3º Caso: dados agrupados com intervalos

Neste caso, devemos inicialmente localizar a classe mediana. Para isso seguimos os seguintes passos:

1º passo: calculamos a ordem  $\frac{1}{2}$ . Independente se  $n$  é par ou ímpar.

2º passo: pela  $F_i$  (Frequência acumulada) identificamos a classe que contém a mediana.

3º passo: utilizamos a fórmula:

$$\bar{x} = l_i + \frac{\left(\frac{n}{2} - \Sigma_f\right)}{F_{Md}} \cdot h$$

Em que:

$l_i$  = limite inferior da classe modal

$n$  = tamanho total da amostra ou número de elementos

$\Sigma_f$  = soma das frequências anteriores à classe mediana

$h$  = amplitude da classe mediana

$F_{Md}$  = Frequência da classe mediana



## Mediana ( $\bar{x}$ )

### 3º Caso: dados agrupados com intervalos

Exemplo: Dada a tabela:

| classe  | $f_i$ | $F_i$ |
|---------|-------|-------|
| 3 - 6   | 2     | 2     |
| 6 - 9   | 5     | 7     |
| 9 - 12  | 8     | 15    |
| 12 - 15 | 3     | 18    |
| 15 - 18 | 1     | 19    |
| Total   | 19    |       |

**1º passo:** calcula-se  $\frac{n}{2}$ . Como  $n = 19$ , temos:  
 $\frac{19}{2} = 9,5$  (elemento)

**2º passo:** Identifica-se a classe mediana pela  $F_i$ .

Neste caso a classe mediana é a 3ª: 9 - 12

**3º passo:** Aplica-se a fórmula:

$$l_i = 9$$

$$\Sigma_f = 7$$

$$h = 12 - 9 = 3$$

$$F_{Md} = 8$$


Portanto:

$$\bar{x} = l_i + \frac{\left(\frac{n}{2} - \Sigma_f\right)}{F_{Md}} \cdot h$$

$$\bar{x} = 9 + \frac{9,5 - 7}{8} \cdot 3 = 9 + \frac{2,5}{8} \cdot 3 = 9 + \frac{7,5}{8} = 9,9375$$

Conclusão 50% dos valores são menores ou iguais a 9,94 e 50% são maiores ou iguais a 9,94





**Prof. MSc. Marcos Alexandruk**

**E-mail: [alexandruk@uni9.pro.br](mailto:alexandruk@uni9.pro.br)**


**<https://github.com/alexandruk/analisededados>**

## Separatrizes

Quartil, Decil, Percentil

## Quartis ( $Q_1$ , $Q_2$ (Md) e $Q_3$ )

Os **quartis** dividem um conjunto ordenado de dados em quatro partes iguais, com cada parte representando 25%.



## Quartis ( $Q_1$ , $Q_2$ (Md) e $Q_3$ )

As notas de nove alunos em uma determinada prova estão apresentadas a seguir:

**73, 74, 77, 52, 85, 59, 73, 84, 92**

Determine a mediana, o 1º e o 3º quartil.

**1º passo:** Ordenar os elementos em ordem crescente:

**52, 59, 73, 73, 74, 77, 84, 85, 92**

**2º passo:** Determinar a mediana (o elemento central):

**$Q_2$  (Mediana) = 52, 59, 73, 73, 74, 77, 84, 85, 92**

**3º passo:** Determinar  $Q_1$  (1º Quartil):

**52, 59, 73, 73, 74, 77, 84, 85, 92**

**$Q_1 = (59+73)/2 = 122/2 = 66$**

**4º passo:** Determinar  $Q_3$  (3º Quartil):

**52, 59, 73, 73, 74, 77, 84, 85, 92**

**$Q_3 = (84+85)/2 = 169/2 = 84,5$**

## Quartis ( $Q_1$ )

### Dados agrupados com intervalos

Exemplo: Dada a tabela:

| classe    | $f_i$             | $F_i$ |
|-----------|-------------------|-------|
| 160 - 164 | 7                 | 7     |
| 164 - 168 | 4                 | 11    |
| 168 - 172 | 5                 | 16    |
| 172 - 176 | 8                 | 24    |
| 176 - 180 | 16                | 40    |
|           | $\Sigma f_i = 40$ |       |

$$* = l_i + \frac{(k \cdot \Sigma f_i - F_{i \text{ anterior}})}{f_i} \cdot h$$

$Q_1$ : calcular  $\frac{1 \cdot n}{4}$ . Como  $n = 40$ , temos:

$$\frac{40}{4} = 10^\circ \text{ (elemento)}$$

**2º passo:** Identifica-se a classe do  $Q_1$  pela  $F_i$ .

Neste caso a classe  $Q_1$  é a 2ª: 164 - 168

**3º passo:** Aplica-se a fórmula:

$$l_i = 164$$

$$k = \frac{1}{4}$$

$$\Sigma f_i = 40$$

$$F_{i \text{ anterior}} = 7$$

$$f_i = 4$$

$$h = 168 - 164 = 4$$

Portanto:

$$Q_1 = 164 + \frac{\left(\frac{1}{4} \cdot 40 - 7\right)}{4} \cdot 4$$

$$Q_1 = 164 + \frac{(10 - 7)}{4} \cdot 4$$

$$Q_1 = 164 + 3 = 167$$

## Quartis ( $Q_2$ )

### Dados agrupados com intervalos

Exemplo: Dada a tabela:

| classe    | $f_i$           | $F_i$ |
|-----------|-----------------|-------|
| 160 - 164 | 7               | 7     |
| 164 - 168 | 4               | 11    |
| 168 - 172 | 5               | 16    |
| 172 - 176 | 8               | 24    |
| 176 - 180 | 16              | 40    |
|           | $\sum f_i = 40$ |       |

$$* = l_i + \frac{(k \cdot \sum f_i - F_{i \text{ anterior}})}{f_i} \cdot h$$

$Q_2$ : calcular  $\frac{2 \cdot n}{4}$ . Como  $n = 40$ , temos:

$$\frac{80}{4} = 20^\circ \text{ (elemento)}$$

**2º passo:** Identifica-se a classe do  $Q_2$  pela  $F_i$ .

Neste caso a classe  $Q_2$  é a 4ª: 172 - 176

**3º passo:** Aplica-se a fórmula:

$$l_i = 172$$

$$k = \frac{1}{2}$$

$$\sum f_i = 40$$

$$F_{i \text{ anterior}} = 16$$

$$f_i = 8$$

$$h = 176 - 172 = 4$$

Portanto:

$$Q_2 = 172 + \frac{\left(\frac{1}{2} \cdot 40 - 16\right)}{8} \cdot 4$$

$$Q_2 = 172 + \frac{(20 - 16)}{8} \cdot 4$$

$$Q_2 = 172 + 2 = 174$$



## Quartis ( $Q_3$ )

### Dados agrupados com intervalos

Exemplo: Dada a tabela:

| classe    | $f_i$           | $F_i$ |
|-----------|-----------------|-------|
| 160 - 164 | 7               | 7     |
| 164 - 168 | 4               | 11    |
| 168 - 172 | 5               | 16    |
| 172 - 176 | 8               | 24    |
| 176 - 180 | 16              | 40    |
|           | $\sum f_i = 40$ |       |

$$* = l_i + \frac{(k \cdot \sum f_i - F_{i \text{ anterior}})}{f_i} \cdot h$$

$Q_3$ : calcular  $\frac{3 \cdot n}{4}$ . Como  $n = 40$ , temos:

$$\frac{120}{4} = 30^\circ \text{ (elemento)}$$

**2º passo:** Identifica-se a classe do  $Q_3$  pela  $F_i$ .

Neste caso a classe  $Q_3$  é a 5ª: 176 - 180

**3º passo:** Aplica-se a fórmula:

$$l_i = 176$$

$$k = \frac{3}{4}$$

$$\sum f_i = 40$$

$$F_{i \text{ anterior}} = 24$$

$$f_i = 16$$

$$h = 180 - 176 = 4$$

Portanto:


$$Q_3 = 176 + \frac{\left(\frac{3}{4} \cdot 40 - 24\right)}{16} \cdot 4$$

$$Q_3 = 176 + \frac{(30 - 24)}{\cancel{16} \text{ } 4} \cdot \cancel{4}$$

$$Q_3 = 176 + \frac{6}{4} = 176 + 1,5 = 177,5$$

## Decil ( $D_1, D_2, D_3 \dots D_{10}$ )

Os **decis** dividem um conjunto ordenado de dados em 10 partes iguais, com cada parte representando 10%.



## Decil

### Dados agrupados com intervalos

Exemplo: Dada a tabela:

| classe    | $f_i$           | $F_i$ |
|-----------|-----------------|-------|
| 160 - 162 | 7               | 7     |
| 162 - 164 | 4               | 11    |
| 164 - 166 | 8               | 19    |
| 166 - 168 | 9               | 28    |
| 168 - 170 | 12              | 40    |
|           | $\sum f_i = 40$ |       |

$$* = l_i + \frac{(k \cdot \sum f_i - F_{i \text{ anterior}})}{f_i} \cdot h$$

$D_2$ : calcular  $\frac{2 \cdot n}{10}$ . Como  $n = 40$ , temos:

$$\frac{80}{10} = 8^\circ \text{ (elemento)}$$

**2º passo:** Identifica-se a classe  $D_2$  pela  $F_i$ .

Neste caso a classe  $D_2$  é a 2ª: 162 - 164

**3º passo:** Aplica-se a fórmula:

$$l_i = 162$$

$$k = \frac{2}{10}$$

$$\sum f_i = 40$$

$$F_{i \text{ anterior}} = 7$$

$$f_i = 4$$

$$h = 164 - 162 = 2$$

Portanto:


$$D_2 = 162 + \frac{\left(\frac{2}{10} \cdot 40 - 7\right)}{4} \cdot 2$$

$$D_2 = 162 + \frac{(8 - 7)}{4} \cdot 2$$

$$D_2 = 162 + \frac{1}{2} = 162 + 0,5 = 162,5$$

## Percentil ( $P_1, P_2, P_3 \dots P_{100}$ )

Os **percentis** dividem um conjunto ordenado de dados em 100 partes iguais, com cada parte representando 1%.



## Percentil

### Dados agrupados com intervalos

Exemplo: Dada a tabela:

| classe    | $f_i$           | $F_i$ |
|-----------|-----------------|-------|
| 160 - 162 | 7               | 7     |
| 162 - 164 | 4               | 11    |
| 164 - 166 | 8               | 19    |
| 166 - 168 | 9               | 28    |
| 168 - 170 | 12              | 40    |
|           | $\sum f_i = 40$ |       |

$$* = l_i + \frac{(k \cdot \sum f_i - F_{i \text{ anterior}})}{f_i} \cdot h$$

$P_{20}$ : calcular  $\frac{20 \cdot n}{100}$ . Como  $n = 40$ , temos:  
 $\frac{800}{100} = 8^\circ$  (elemento)

**2º passo:** Identifica-se a classe  $P_{20}$  pela  $F_i$ .

Neste caso a classe  $P_{20}$  é a 2ª: 162 - 164

**3º passo:** Aplica-se a fórmula:

$$l_i = 162$$

$$k = \frac{20}{100}$$

$$\sum f_i = 40$$

$$F_{i \text{ anterior}} = 7$$

$$f_i = 4$$

$$h = 164 - 162 = 2$$

Portanto:

$$P_{20} = 162 + \frac{\left(\frac{20}{100} \cdot 40 - 7\right)}{4} \cdot 2$$

$$P_{20} = 162 + \frac{(8 - 7)}{4} \cdot 2$$

$$P_{20} = 162 + \frac{1}{2} = 162 + 0,5 = 162,5$$

## R (quartil, decil e percentil)

```
x <- c(69, 70, 75, 66, 83, 88, 66, 63, 61, 68, 73, 57, 52, 58, 77)
```

### quartis

```
quantile(x)
```

### decis

```
quantile(x, prob = seq(0, 1, length = 11))
```

### percentis

```
quantile(x, prob = seq(0, 1, length = 101))
```

### resumo

```
summary(x)
```

## R (entrada de dados externos – arquivo .csv)

### Criar o arquivo teste.txt:

```
nome,idade  
Fulano,20  
Beltrano,30  
Sicrano,40
```

### Importar os dados:

```
teste<-read.table("c:/Aulas/teste.txt",header=T,sep=",")
```

## Medidas de Dispersão

desvio médio, variância, desvio padrão e coeficiente de variação



## Média, moda e mediana

A **média**, apesar de ser uma medida muito utilizada em Estatística, é muitas vezes insuficiente para caracterizar aceitavelmente uma distribuição.

A **moda** e a **mediana** também são medidas que nem sempre são suficientes para caracterizar um conjunto de dados.

Em alguns casos, temos que recorrer a outros parâmetros, chamados de medidas de dispersão.

As medidas de dispersão são medidas estatísticas utilizadas para avaliar o grau de variabilidade ou dispersão dos valores em torno da média. Servem para medir a representatividade da média.

## Média, moda e mediana

Observe as séries:

a. 10, 1, 18, 20, 35, 3, 7, 15, 11, 10

b. 12, 13, 13, 14, 12, 14, 12, 14, 13, 13

c. 13, 13, 13, 13, 13, 13, 13, 13, 13, 13

Estes dados possuem a mesma média 13. No entanto, são sequências completamente distintas do ponto de vista da variabilidade de dados.

Na série "c" não há dispersão.

Comparando-se as séries "a" e "b", percebe-se que "a" apresenta maior dispersão em torno da média do que "b".

Isso indica que necessitamos de outro tipo de medida para distinguir e comparar os três conjuntos de dados.

O critério frequentemente usado para tal fim é aquele que mede a maior ou menor dispersão dos dados em torno da média, e as medidas mais usadas são:

- **desvio médio**
- **variância**
- **desvio padrão**
- **coeficiente de variação**

## Desvio médio (Dm)

É a análise dos desvios em torno da média. Calculamos inicialmente a média da amostra ( $\bar{x}$ ):  
Em seguida, identificamos a distância de cada elemento da amostra para sua média:

$$|d_i| = |x_i - \bar{x}|$$

Finalmente, calculamos o desvio médio:

$$\frac{\sum |d_i| F_i}{n} \quad \text{ou} \quad \frac{\sum |x_i - \bar{x}| F_i}{n}$$

Onde  $x_i$  é a variável,  $\bar{x}$  a média e  $n$  o número de dados da amostra.

Dessa forma, o desvio médio é a média aritmética dos valores absolutos dos desvios.

| $x_i$ | $F_i$ | $x_i F_i$ | $ d_i  =  x_i - \bar{x} $ | $ d_i  F_i$             |
|-------|-------|-----------|---------------------------|-------------------------|
| 2     | 5     | 10        | $ 2 - 4,17  = 2,17$       | $2,17 \times 5 = 10,85$ |
| 3     | 4     | 12        | $ 3 - 4,17  = 1,17$       | $1,17 \times 4 = 4,68$  |
| 5     | 4     | 20        | $ 5 - 4,17  = 0,83$       | $0,83 \times 4 = 3,32$  |
| 6     | 2     | 12        | $ 6 - 4,17  = 1,83$       | $1,83 \times 2 = 3,66$  |
| 7     | 3     | 21        | $ 7 - 4,17  = 2,83$       | $2,83 \times 3 = 8,49$  |
| Total | 18    | 75        |                           | 31                      |

$$\bar{x} = \frac{\sum x_i F_i}{n} = \frac{75}{18} = 4,17$$

$$Dm = \frac{\sum |d_i| F_i}{n} = \frac{31}{18} = 1,72$$

## Variância (Var)

É a média aritmética dos quadrados dos desvios. Logo:

$$Var = \frac{\sum d_i^2 F_i}{n}$$

| $x_i$ | $F_i$ | $x_i F_i$ | $ d_i  =  x_i - \bar{x} $ | $d_i^2$ | $d_i^2 F_i$ |
|-------|-------|-----------|---------------------------|---------|-------------|
| 2     | 5     | 10        | $ 2 - 4,17  = 2,17$       | 4,71    | 23,55       |
| 3     | 4     | 12        | $ 3 - 4,17  = 1,17$       | 1,37    | 5,48        |
| 5     | 4     | 20        | $ 5 - 4,17  = 0,83$       | 0,69    | 2,76        |
| 6     | 2     | 12        | $ 6 - 4,17  = 1,83$       | 3,35    | 6,7         |
| 7     | 3     | 21        | $ 7 - 4,17  = 2,83$       | 8,01    | 24,03       |
| Total | 18    | 75        |                           |         | 62,52       |

$$Var = \frac{\sum d_i^2 F_i}{n} = \frac{62,52}{18} = 3,47$$

## Desvio padrão (Dp)

Como para calcular a variância trabalhamos com os quadrados dos desvios, podemos ter uma incompatibilidade em relação às unidades dos valores da variável considerada.

Para contornar esse problema, temos o desvio padrão, que é a raiz quadrada da variância:

$$Dp = \sqrt{Var}$$

| $x_i$ | $F_i$ | $x_i F_i$ | $ d_i  =  x_i - \bar{x} $ | $d_i^2$ | $d_i^2 F_i$ |
|-------|-------|-----------|---------------------------|---------|-------------|
| 2     | 5     | 10        | $ 2 - 4,17  = 2,17$       | 4,71    | 23,55       |
| 3     | 4     | 12        | $ 3 - 4,17  = 1,17$       | 1,37    | 5,48        |
| 5     | 4     | 20        | $ 5 - 4,17  = 0,83$       | 0,69    | 2,76        |
| 6     | 2     | 12        | $ 6 - 4,17  = 1,83$       | 3,35    | 6,7         |
| 7     | 3     | 21        | $ 7 - 4,17  = 2,83$       | 8,01    | 24,03       |
| Total | 18    | 75        |                           |         | 62,52       |

$$Var = \frac{\sum d_i^2 F_i}{n} = \frac{62,52}{18} = 3,47$$

$$Dp = \sqrt{Var} = \sqrt{3,47} = 1,86$$

Resumindo: a distribuição possui média **4,17**. Isto é, seus valores estão em torno de **4,17** e seu grau de concentração é de **1,72**, medido pelo desvio médio e de **1,86**, medido pelo desvio padrão.

## Coeficiente de Variação (CV)

O desvio padrão por si só não nos diz muita coisa; para contornar esta dificuldade, usamos o coeficiente de variação.

Trata-se de uma medida relativa de dispersão útil para a comparação em termos relativos do grau de concentração em torno da média de séries distintas.

É expresso em porcentagens e dado por:

$$CV = \frac{Dp}{\bar{x}} \cdot 100$$

Onde  $Dp$  é o desvio padrão e  $\bar{x}$ , a média da distribuição.

Diz-se que a distribuição possui pequena variabilidade (dispersão) quando o  $CV$  apresentar valor até 15%; média dispersão quando estiver acima de 15% até 30% e grande dispersão quando superar 30%.

## Coeficiente de Variação (CV)

Considere a tabela abaixo:

| $x_i$ | $F_i$ | $x_i F_i$ | $ d_i  =  x_i - \bar{x} $ | $d_i^2$ | $d_i^2 F_i$ |
|-------|-------|-----------|---------------------------|---------|-------------|
| 2     | 5     | 10        | $ 2 - 4,17  = 2,17$       | 4,71    | 23,55       |
| 3     | 4     | 12        | $ 3 - 4,17  = 1,17$       | 1,37    | 5,48        |
| 5     | 4     | 20        | $ 5 - 4,17  = 0,83$       | 0,69    | 2,76        |
| 6     | 2     | 12        | $ 6 - 4,17  = 1,83$       | 3,35    | 6,7         |
| 7     | 3     | 21        | $ 7 - 4,17  = 2,83$       | 8,01    | 24,03       |
| Total | 18    | 75        |                           |         | 62,52       |

Baixa dispersão  $CV \leq 15\%$

Média dispersão:  $15\% < CV < 30\%$

Alta dispersão:  $CV \geq 30\%$

$$Var = \frac{\sum d_i^2 F_i}{n} = \frac{62,52}{18} = 3,47$$

$$Dp = \sqrt{Var} = \sqrt{3,47} = 1,86$$

$$\bar{x} = 4,17$$

$$CV = \frac{Dp}{\bar{x}} \cdot 100$$

$$CV = \frac{1,86}{4,17} \cdot 100 = 44,60\%$$

***alta dispersão***

## Coeficiente de Variação (CV)

Exemplo: Numa empresa, o salário médio dos homens é de R\$ 4.000,00, com desvio padrão de R\$ 1.500,00 e, o das mulheres, é em média de R\$ 3.000,00, com desvio padrão de R\$ 1.200,00. Então:

$$CV_H = \frac{1500}{4000} \cdot 100 = 37,5\%$$

$$CV_M = \frac{1200}{3000} \cdot 100 = 40\%$$

Logo, podemos concluir que os salários das mulheres apresentam maior dispersão que os dos homens.

De modo geral, quanto menor o *CV*, menos dispersos estão os dados em torno da média, que passa a ser mais representativa do conjunto de dados.



## Medidas de Dispersão (Exemplo)

Encontre o desvio médio, o desvio padrão e o coeficiente de variação da distribuição:

| <i>Classes</i> | $x_i$ | $F_i$ | $x_i F_i$ | $ d_i $ | $ d_i  F_i$ | $d_i^2$ | $d_i^2 F_i$ |
|----------------|-------|-------|-----------|---------|-------------|---------|-------------|
| 2 † 4          | 3     | 2     | 6         | 4,2     | 8,4         | 17,64   | 35,28       |
| 4 † 6          | 5     | 4     | 20        | 2,2     | 8,8         | 4,48    | 19,36       |
| 6 † 8          | 7     | 7     | 49        | 0,2     | 1,4         | 0,04    | 0,28        |
| 8 † 10         | 9     | 4     | 36        | 1,8     | 7,2         | 3,24    | 12,96       |
| 10 † 12        | 11    | 3     | 33        | 3,8     | 11,4        | 14,44   | 43,32       |
|                |       | 20    | 144       |         | 37,2        |         | 111,20      |

# Introdução à teoria da amostragem

## Introdução à teoria da amostragem

### Objetivo:

Determinar o espaço amostral, os eventos desse espaço e calcular o número de elementos destes conjuntos.

## Experimento aleatório (E)

Experimentos aleatórios são aqueles que, mesmo repetidos várias vezes sob condições semelhantes, **apresentam resultados imprevisíveis**.

### Exemplo:

Em uma afirmação do tipo: "é provável que meu time ganhe a partida de hoje" pode resultar:

- Que o time perca.
- Que o time ganhe.
- Que o time empate.

**O resultado é imprevisível e depende do acaso.** Fenômenos como esses são chamados **fenômenos aleatórios** ou **experimentos aleatórios**.

## Espaço amostral (S)

É o conjunto de todos os possíveis resultados de um experimento aleatório (E). Indicamos o espaço amostral por S e o número de elementos de S por  $n(S)$ .

### Exemplo:

E: jogar um dado cúbico e observar o número da face de cima:

$$S = \{1, 2, 3, 4, 5, 6\}$$

$$n(S) = 6$$

E: jogar uma moeda e observar o resultado:

$$S = \{\text{cara}, \text{coroa}\}$$

$$n(S) = 2$$

E: lançar duas moedas e observar o resultado na face de cada uma:

$$S = \{(\text{cara}, \text{cara}), (\text{cara}, \text{coroa}), (\text{coroa}, \text{cara}), (\text{coroa}, \text{coroa})\}$$

$$n(S) = 4$$

## Evento

É qualquer subconjunto do espaço amostral  $S$  de um experimento aleatório ( $E$ ).

### Exemplo:

$E$ : lançar um dado cúbico e observar o número da face de cima:

$$S = \{1, 2, 3, 4, 5, 6\}$$

$$n(S) = 6$$

### Exemplos de eventos de $S$ :

$A$ : sair número par:  $\{2, 4, 6\}$

$$n(A) = 3$$

$B$ : sair número primo:  $\{2, 3, 5\}$

$$n(B) = 3$$

## Combinações de eventos

Uma urna contém 3 bolas pretas e 3 bolas vermelhas. Dessa urna são retiradas, sucessivamente, 3 bolas.

Determine o espaço amostral.

Determine os eventos.

A: as 3 bolas têm a mesma cor

B: exatamente 2 das bolas são pretas

C: as 3 bolas são vermelhas

D: o número de bolas pretas é igual ao número de bolas vermelhas

### Solução:

$S = \{(P, P, P), (P, P, V), (P, V, P), (P, V, V), (V, P, P), (V, P, V), (V, V, P), (V, V, V)\}$

$n(S) = 8$

$A = \{(P, P, P), (V, V, V)\}$

$n(A) = 2$

$B = \{(P, P, V), (P, V, P), (V, P, P)\}$

$n(B) = 3$

$C = \{(V, V, V)\}$

$n(C) = 1$

$D = \{ \}$

$n(D) = 0$

*O conjunto vazio é chamado evento impossível.*

*Quando o evento coincide com o espaço amostral, ele é chamado evento certo.*

## Combinações de eventos

### União de dois eventos

Sejam **A** e **B** dois eventos, então **A U B** é um evento que ocorrerá se, e somente se, **A** ou **B** ocorrem.

Considere o exemplo:

E: lançamento um dado cúbico e observação do número voltado para cima

**S = {1, 2, 3, 4, 5, 6}**

**A**: ocorrência de um número ímpar: **{1, 3, 5}**

**B**: ocorrência de um número par primo: **{2}**

Logo, **A U B**: ocorrência de um número ímpar ou um número par primo:

**A U B = {1, 2, 3, 5}**



## Combinações de eventos

### União de dois eventos

Sejam **A** e **B** dois eventos, então  $A \cap B$  é um evento que ocorrerá se, e somente se, **A** e **B** ocorrem simultaneamente.

Observação: em particular, se  $A \cap B = \emptyset$ , **A** e **B** são chamados mutuamente exclusivos.

Considere o exemplo:

E: lançamento um dado cúbico e observação do número voltado para cima

$S = \{1, 2, 3, 4, 5, 6\}$

A: ocorrência de um número par:  $\{2, 4, 6\}$

B: ocorrência de um número múltiplo de 4:  $\{4\}$

Logo,  $A \cap B$ : ocorrência de um número par e múltiplo de 4:

$A \cap B = \{4\}$

## Combinações de eventos

### Complementar de um evento

Dado um evento  $A$ , o conjunto formado pelos elementos de  $S$  que não pertencem a  $A$  se chama evento complementar de  $A$  em relação a  $S$  e indica-se por  $\bar{A}$ .

Considere o exemplo:

E: lançamento um dado cúbico e observação do número voltado para cima

$$S = \{1, 2, 3, 4, 5, 6\}$$

A: ocorrência de um número par:  $\{2, 4, 6\}$

$$\bar{A} = \{1, 3, 5\}$$

$$A \cup \bar{A} = \{1, 2, 3, 4, 5, 6\} = S$$

$$A \cap \bar{A} = \emptyset$$

## Fatorial, permutação, arranjo e combinação

## Fatorial

O fatorial de um número natural  $n$  é representado por  $n!$  (lê-se  $n$  fatorial), em que:

$$n! = n \cdot (n - 1) \cdot (n - 2) \cdot \dots \cdot 3 \cdot 2 \cdot 1, \text{ para } n \geq 2$$

$$1! = 1$$

$$0! = 1$$

Exemplos:

$$4! = 4 \cdot 3 \cdot 2 \cdot 1 = 24$$

$$7! = 7 \cdot 6 \cdot 5 \cdot 4 \cdot 3 \cdot 2 \cdot 1 = 5040$$

$$n! = n \cdot (n - 1)! \text{ ou } n \cdot (n - 1) \cdot (n - 2)! \dots$$

Exemplo: simplificar as expressões:

$$\frac{8!}{5! \cdot 3!} = \frac{8 \cdot 7 \cdot \cancel{6} \cdot \cancel{5}!}{\cancel{5}! \cdot 3!} = \frac{8 \cdot 7 \cdot 6}{3 \cdot 2 \cdot 1} = 56$$

$$\frac{(n + 1)!}{n!} = \frac{(n + 1) \cdot \cancel{n}!}{\cancel{n}!} = n + 1$$

## Permutação

Dado um conjunto de  $n$  elementos, chama-se permutação simples dos  $n$  elementos, qualquer sequência – agrupamento ordenado – desses  $n$  elementos.

$$P_n = n!$$

Exemplos:

Dados três cartões coloridos: Amarelo (A), Laranja (L) e Vermelho (V). Quantas sequências diferentes podemos obter ao enfileirar os três cartões?

$$P_n = 3! = 3 \cdot 2 \cdot 1 = 6$$

(A,L,V) (A,V,L) (L,A,V) (L,V,A) (V,A,L) (V,L,A)

Um restaurante funciona cinco dias por semana. Elaborou, portanto, cinco menus diferentes, designados como M1, M2, M3, M4 e M5. De quantas maneiras é possível escolher esses menus de forma que não haja repetição na semana?

$$P_n = 5! = 5 \cdot 4 \cdot 3 \cdot 2 \cdot 1 = 120$$

## Arranjo

Chama-se arranjo simples de  $n$  elementos distintos tomados  $p$  a  $p$  ( $p \leq n$ ), todo agrupamento **ordenado** formado por  $p$  elementos escolhidos entre os  $n$  elementos dados. (*muda a ordem, muda o grupo:  $AB \neq BA$* )

### Arranjo Simples

Considere um conjunto com  $n$  elementos distintos. Qualquer sequência de  $p$  desses elementos (todos distintos) é chamada de Arranjo Simples ( $0 \leq p \leq n$ , com  $n$  e  $p$  naturais). Dizemos arranjo simples de  $n$  elementos tomados  $p$  a  $p$ , e simbolizamos por  $A_{n,p}$

Esse arranjo simples pode ser calculado da seguinte forma:

$$A_{n,p} = \frac{n!}{(n-p)!}$$

Arranjos com a totalidade dos elementos, ou seja,  $A_{n,n}$  são as permutações de  $n$  elementos.

$$A_{n,n} = P_n = n!$$

Exemplo:

Em uma urna de sorteio de prêmios existem dez bolas enumeradas de 0 a 9. Determine o número de possibilidades existentes num sorteio cujo prêmio é formado por uma sequência de 6 algarismos.

$$A_{10,6} = \frac{n!}{(n-p)!} = \frac{10!}{(10-6)!} = \frac{10!}{4!} = \frac{10 \cdot 9 \cdot 8 \cdot 7 \cdot 6 \cdot 5 \cdot \cancel{4!}}{\cancel{4!}} = 10 \cdot 9 \cdot 8 \cdot 7 \cdot 6 \cdot 5 = 151200$$

## Combinação

Denominam-se combinações simples de  $n$  elementos tomados  $p$  a  $p$  ( $p \leq n$ ), aos diferentes subconjuntos que contêm  $p$  elementos, **sem referência à ordem**. (*muda a ordem, o grupo permanece o mesmo:  $AB = BA$* )

Uma combinação simples é representada da seguinte forma:

$$C_{n,p} = \frac{n!}{p! (n - p)!}$$

Exemplo:

Dado o conjunto de 4 elementos  $\{a,b,c,d\}$ , quantas combinações formadas com 2 elementos são possíveis?

$$C_{4,2} = \frac{n!}{p! (n - p)!} = \frac{4!}{2! (4 - 2)!} = \frac{4 \cdot 3 \cdot \cancel{2!}}{2! \cdot \cancel{2!}} = \frac{12}{2} = 6$$

$\{a,b\}$   $\{a,c\}$   $\{a,d\}$   $\{b,c\}$   $\{b,d\}$   $\{c,d\}$

$C_{n,p}$  ou  $\binom{n}{p}$  são formas de indicar o número de combinações de  $n$  elementos  $p$  a  $p$ , com  $n \geq p$ .

$\binom{n}{p}$  também é chamado **coeficiente binomial** porque é utilizado em uma fórmula matemática chamada **teorema binomial**.

## Exercícios

**Fatorial:** Calcule os seguintes fatoriais:

$$4!$$

$$\frac{10!}{8!}$$

**Permutação:** Dados cinco cartões coloridos, quantas sequências diferentes podemos obter ao enfileirar os cinco cartões?

**Arranjo:** Suponha que, em uma corrida de oito cavalos, você esteja tentando acertar a ordem de chegada dos três primeiros finalistas, sem nada saber sobre os cavalos. Quantas finais são possíveis?

**Combinação:** Sabe-se que um júri foi formado por 7 pessoas, selecionadas de um grupo de 21 pessoas. Neste caso, temos um agrupamento de ordem 7 (as 7 pessoas que formam o júri). A ordem de escolha dessas 7 pessoas não muda o grupo. Portanto, quantas combinações são possíveis?

Quantos jogos diferentes (com seis números em cada jogo) uma pessoa precisaria fazer para ter 100% de certeza de ganhar o prêmio em um determinado sorteio da Mega Sena? (São sorteados 6 números dentre 60 em cada sorteio.)



## Probabilidade de um evento

## Probabilidade de ocorrência de um evento

Dado um experimento aleatório, sendo  $S$  o seu espaço amostral, vamos admitir que todos os elementos de  $S$  tenham a mesma chance de acontecer, chamamos de probabilidade de um evento  $A$  o número real  $P(A)$ , tal que:

$$P(A) = \frac{n(A)}{n(S)}$$

Em que:

$n(A)$  = número de elementos do evento  $A$

$n(S)$  = número de elementos do espaço amostral  $S$

## Probabilidade de ocorrência de um evento

Considerando o lançamento de um dado, determine a probabilidade de ocorrer na face superior:

**Um número par**

Solução:

Temos que:  $S = \{1, 2, 3, 4, 5, 6\}$ , logo  $n(S) = 6$

$A = \{2, 4, 6\}$ , logo  $n(A) = 3$

Então:  $P(A) = \frac{3}{6} = \frac{1}{2}$  ou 50%

## Probabilidade de ocorrência de um evento

Considerando o lançamento de um dado, determine a probabilidade de ocorrer na face superior:

**O número 2**

Solução:

Temos que:  $S = \{1, 2, 3, 4, 5, 6\}$ , logo  $n(S) = 6$

$B = \{2\}$ , logo  $n(B) = 1$

Então:  $P(B) = \frac{1}{6}$ , ou 16,67%

## Probabilidade de ocorrência de um evento

Considerando o lançamento de um dado, determine a probabilidade de ocorrer na face superior:

**Um número menor ou igual a 6**

Solução:

Temos que:  $S = \{1, 2, 3, 4, 5, 6\}$ , logo  $n(S) = 6$

$C = \{1, 2, 3, 4, 5, 6\}$ , logo  $n(C) = 6$

Então:  $P(C) = \frac{6}{6} = 1$ , ou 100%

## Probabilidade de ocorrência de um evento

Considerando o lançamento de um dado, determine a probabilidade de ocorrer na face superior:

**Um número maior que 6**

Solução:

Temos que:  $S = \{1, 2, 3, 4, 5, 6\}$ , logo  $n(S) = 6$

$D = \{\dots\}$ , logo  $n(D) = 0$

Então:  $P(D) = \frac{0}{6} = 0$ , ou 0%

## Eventos complementares

Sabemos que um evento pode ocorrer ou não. Sendo **p** a probabilidade de que ele ocorra (**sucesso**) e **q** a probabilidade de que ele não ocorra (**insucesso**), então: **p + q = 1** ou **q = 1 – p**:

Exemplo: vimos que, no lançamento de um dado, a probabilidade de ocorrer o número 2 na face superior é  $\frac{1}{6}$  ou 16,67%.

Logo, a probabilidade de não tirar 2 no lançamento é  $1 - \frac{1}{6} = \frac{5}{6}$  ou 83,33%.

## Exercício resolvido 1


Uma moeda é lançada 3 vezes sucessivamente. Qual a probabilidade de obtermos:

- Resultados iguais: 3 vezes cara ou 3 vezes coroa
- Pelo menos uma cara
- Exatamente uma cara
- Número de coroas maior que o número de caras



## Exercício resolvido 1

- Resultados iguais: 3 vezes cara (C) ou 3 vezes coroa (K)



Solução:

$$S = \{(CCC), (CCK), (CKC), (CKK), (KCC), (KCK), (KKC), (KKK)\}$$

$$n(S) = 8$$


$$A = \{(CCC), (KKK)\}$$

$$n(A) = 2$$

$$\text{Logo, } P(A) = \frac{2}{8} = \frac{1}{4} = 0,25 = 25\%$$

## Exercício resolvido 1

- Pelo menos uma cara (C)



Solução:

$$S = \{(CCC), (CCK), (CKC), (CKK), (KCC), (KCK), (KKC), (KKK)\}$$

$$n(S) = 8$$


$$B = \{(CCC), (CCK), (CKC), (CKK), (KCC), (KCK), (KKC)\}$$

$$n(B) = 7$$

$$\text{Logo, } P(B) = \frac{7}{8} = 0,875 = 87,5\%$$

## Exercício resolvido 1

- Exatamente uma cara (C)



Solução:

$$S = \{(CCC), (CCK), (CKC), (CKK), (KCC), (KCK), (KKC), (KKK)\}$$

$$n(S) = 8$$


$$C = \{(CKK), (KCK), (KKC)\}$$

$$n(C) = 3$$

$$\text{Logo, } P(C) = \frac{3}{8} = 0,375 = 37,5\%$$

## Exercício resolvido 1

- Número de coroas (K) maior que o número de caras (C)



Solução:

$S = \{(CCC), (CCK), (CKC), (CKK), (KCC), (KCK), (KKC), (KKK)\}$

$n(S) = 8$

$D = \{(CKK), (KCK), (KKC), (KKK)\}$

$n(D) = 4$

Logo,  $P(D) = \frac{4}{8} = \frac{1}{2} = 0,50 = 50\%$

## Exercício resolvido 2

Uma equipe de **doze pessoas** é formada por **nove homens** e **três mulheres**. Dessas pessoas, duas serão sorteadas para compor uma comissão. Qual é a probabilidade de a comissão ser formada por:

- Duas mulheres
- Dois homens
- Um homem e uma mulher

**Solução:** Vamos, primeiramente, calcular o número de elementos do espaço amostral  $S$ ; para isso, devemos considerar um grupo de 12 pessoas, do qual serão retirados 2 elementos, não importando a ordem, o que corresponde ao número de combinações de 12, tomados 2 a 2:

$$C_{n,p} = \frac{n!}{p! (n - p)!}$$

$$n(S) = C_{12,2} = \frac{12!}{(12-2)! 2!} = \frac{12!}{10! 2!} = \frac{10 \cdot 11 \cdot 10!}{10! 2!} = \frac{12 \cdot 11}{2 \cdot 1} = \frac{132}{2} = 66$$

## Exercício resolvido 2

- Comissões formadas por 2 mulheres, de um total de 3 mulheres:

$$n(A) = C_{3,2} = \frac{3!}{(3-2)!2!} = \frac{3!}{1!2!} = \frac{6}{2} = 3$$

$$\text{Logo, } P(A) = \frac{n(A)}{n(S)} = \frac{3}{66} = \frac{1}{22} = 0,045 = 4,5\%$$

## Exercício resolvido 2

- Comissões formadas por 2 homens, de um total de 9 homens:

$$n(B) = C_{9,2} = \frac{9!}{(9-2)!2!} = \frac{9 \cdot 8 \cdot 7!}{7!2!} = \frac{72}{2} = 36$$

$$\text{Logo } P(B) = \frac{n(B)}{n(S)} = \frac{36}{66} = \frac{6}{11} = 0,545 = 54,5\%$$

## Exercício resolvido 2

- Comissões formadas por 1 homem (de um total de 9) e 1 mulher (de um total de 3):

$$n(C) = C_{9,1} \cdot C_{3,1} = \frac{9!}{(9-1)! 1!} \cdot \frac{3!}{(3-1)! 1!} = \frac{9!}{8!} \cdot \frac{3!}{2!} = \frac{9 \cdot 8!}{8!} \cdot \frac{3 \cdot 2!}{2!} = 9 \cdot 3 = 27$$

$$\text{Logo } P(C) = \frac{n(C)}{n(S)} = \frac{27}{66} = \frac{9}{22} = 0,409 = 40,9\%$$